DỰ ĐOÁN CƯỜNG ĐỘ CARBON CỦA NGÀNH ĐIỆN BẰNG MACHINE LEARNING SỬ DỤNG DỮ LIỆU OUR WORLD IN DATA GIAI ĐOẠN 2000–2025

Nguyễn Thành Long, Nguyễn Đức Huy, Hồ Quốc Sử, Bùi Lê Thanh Ngân
Khoa Công nghệ Thông tin – Trường Đại học Công Thương Thành phố Hồ Chí Minh
1001260011@huit.edu.vn

Ngày 25 tháng 9 năm 2026

Abstract

Nghiên cứu xây dựng một quy trình học máy có thể tái lập để ước lượng cường độ phát thải vòng đời của điện từ cơ cấu nguồn và các đặc trưng hệ thống điện cấp quốc gia. Hai nguồn chính thức của Our World in Data (OWID) được ghép theo mã ISO-3 và năm: bộ OWID Energy cho biến đầu vào và OWID Grapher/Ember cho biến đích, đo bằng gCO_2e/kWh. Sau kiểm tra chất lượng, tập phân tích giai đoạn 2000–2025 gồm 5281 quan sát thuộc 212 quốc gia. Dữ liệu được chia theo thời gian thành train 2000–2018, validation 2019–2021 và test 2022–2025. Ba mô hình Linear Regression, Random Forest và XGBoost được so sánh bằng MAE, RMSE và R^2; mọi bước điền khuyết và chuẩn hóa được fit bên trong pipeline để ngăn rò rỉ dữ liệu. Trên tập test giữ lại, XGBoost đạt MAE 24.25 gCO_2e/kWh, RMSE 41.03 gCO_2e/kWh và $R^2 = 0.972$, là kết quả tốt nhất trong ba mô hình. Phân tích SHAP xác định `hydro_share_elec` có độ quan trọng trung bình lớn nhất đối với XGBoost. Kết quả cho thấy quan hệ phi tuyến giữa cơ cấu phát điện và cường độ carbon có thể được mô hình hóa hiệu quả, nhưng không chứng minh quan hệ nhân quả và không nên được diễn giải như dự báo nhiều năm trong tương lai.

Từ khóa: cường độ carbon, ngành điện, Our World in Data, Random Forest, XGBoost, SHAP, chia dữ liệu theo thời gian.

1 Giới thiệu

Khử carbon trong hệ thống điện là một thành phần trung tâm của quá trình chuyển dịch năng lượng. Một thước đo trực tiếp để so sánh các hệ thống điện là cường độ carbon: lượng phát thải khí nhà kính trên mỗi đơn vị điện sản xuất. Chỉ số trong nghiên cứu này sử dụng cách tính vòng đời, bao gồm các giai đoạn thượng nguồn, chuỗi cung ứng và chế tạo, thay vì chỉ phát thải tại nhà máy điện [1]. Vì cơ cấu phát điện thay đổi theo quốc gia và thời gian, quan hệ giữa tỷ trọng từng nguồn với cường độ carbon có thể phi tuyến và có tương tác.

Mục tiêu nghiên cứu là trả lời câu hỏi: *các mô hình học máy giám sát có thể ước lượng cường độ carbon điện cấp quốc gia trong các năm tương lai gần tốt đến mức nào khi chỉ sử dụng thông tin cơ cấu nguồn điện và quy mô sử dụng điện cùng năm?* Đây là bài toán ước lượng/nowcasting trên dữ liệu bảng, không phải dự báo dài hạn. Ba đóng góp chính gồm:

- một quy trình dữ liệu có provenance, checksum và quy tắc lọc công khai;
- so sánh công bằng Linear Regression, Random Forest và XGBoost trên một phép chia hoàn toàn theo thời gian;

- phân tích feature importance, permutation importance và SHAP, kèm giới hạn diễn giải không nhân quả.

2 Cơ sở và công trình liên quan

Linear Regression được dùng làm đường cơ sở dễ diễn giải. Random Forest kết hợp nhiều cây quyết định được huấn luyện trên các mẫu và tập con đặc trưng ngẫu nhiên, qua đó giảm phương sai so với một cây đơn [4]. XGBoost là hệ thống gradient tree boosting tối ưu hóa tuần tự một hàm mất mát có điều chuẩn, đồng thời hỗ trợ thực thi hiệu quả trên dữ liệu bảng [5].

Đối với giải thích mô hình, SHAP phân rã dự đoán thành đóng góp của từng đặc trưng dựa trên giá trị Shapley [6]. SHAP giúp mô tả mô hình đã học nhưng không biến liên hệ thống kê thành bằng chứng nhân quả. Vì các tỷ trọng nguồn điện có quan hệ cấu thành và tương quan mạnh, thứ hạng importance cũng cần được đọc như mô tả hành vi dự báo, không phải tác động can thiệp.

3 Dữ liệu và phương pháp

3.1 Nguồn dữ liệu và biến đích

Bộ OWID Energy được cập nhật định kỳ và trình bày mỗi hàng cho một địa điểm–năm, kèm codebook mô tả chỉ báo [2]. Biến đích được tải từ trang OWID "Lifecycle carbon intensity of electricity generation", có nguồn gốc Ember 2026 và được OWID xử lý [1, 3]. Snapshot dùng trong thí nghiệm có phạm vi biến đích 1990–2025; nghiên cứu chỉ giữ 2000–2025. Mọi tệp đầu vào được lưu cùng SHA-256 tại `outputs/carbon_intensity/tables/data_provenance.json`.

Biến đích y là cường độ phát thải vòng đời, đơn vị gCO_2e/kWh. Nghiên cứu chỉ giữ hàng có mã ISO-3 để loại tổng hợp khu vực, nhóm thu nhập và thế giới. Không sử dụng cột `carbon_intensity_elec`, tổng phát thải điện hoặc bất kỳ biến nào được suy ra trực tiếp từ y làm đầu vào.

3.2 Đặc trưng và tiền xử lý

Mười hai đặc trưng gồm tỷ trọng điện than, khí, dầu, thủy điện, hạt nhân, gió, mặt trời, sinh khối và tái tạo khác; tỷ lệ nhập khẩu điện ròng trên nhu cầu; logarit $\log(1 + x)$ của điện bình quân đầu người; và năm. Mỗi hàng phải có ít nhất 8 trong 11 biến nguồn trước biến đổi; quy tắc này loại 409 hàng quá thưa. Giá trị còn thiếu được điền bằng median học từ tập fit hiện hành. Linear Regression bổ sung chuẩn hóa StandardScaler; mô hình cây không cần chuẩn hóa. Tiền xử lý được đặt trong pipeline nhằm bảo đảm median và tham số scale không học từ validation hoặc test.

3.3 Chia dữ liệu theo thời gian

Tập train gồm 2000–2018 (3944 hàng), validation gồm 2019–2021 (632 hàng), và test gồm 2022–2025 (705 hàng). Không có năm trùng giữa các tập. Lưới siêu tham số nhỏ của Random Forest và XGBoost chỉ được chọn theo RMSE validation. Sau khi chọn cấu hình cho từng họ mô hình, mô hình được fit lại trên train+validation rồi đánh giá đúng một lần trên test. Cách chia này mô phỏng sự dịch chuyển theo thời gian tốt hơn chia ngẫu nhiên, dù cùng quốc gia có thể xuất hiện ở các giai đoạn khác nhau.

3.4 Mô hình và tiêu chí đánh giá

Linear Regression là baseline. Random Forest khảo sát độ sâu không giới hạn hoặc 16; tham số `min_samples_leaf` bằng 1 hoặc 3, với 500 cây. XGBoost khảo sát số cây 400/700, độ sâu 3/6 và learning rate 0,03/0,07; subsampling hàng và cột đều bằng 0,9. Seed của toàn bộ thí nghiệm là 42.

Với n quan sát, sai số trung bình tuyệt đối và căn sai số bình phương trung bình được tính như sau:

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \tag{1}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}. \tag{2}$$

Hệ số xác định là

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}. \tag{3}$$

MAE và RMSE càng nhỏ càng tốt; R^2 càng gần 1 càng tốt. RMSE nhạy hơn với sai số lớn và được dùng để chọn siêu tham số.

4 Kết quả thực nghiệm

4.1 Phạm vi dữ liệu

Sau quy tắc lọc, bộ mô hình hóa có 5281 quan sát của 212 quốc gia. Hình 1 cho thấy số quan sát và trung bình biến đích theo năm. Hai đường đứt đánh dấu ranh giới train–validation và validation–test. Số quan sát năm 2025 thấp hơn rõ rệt, phù hợp với trạng thái dữ liệu một phần tại thời điểm tải.

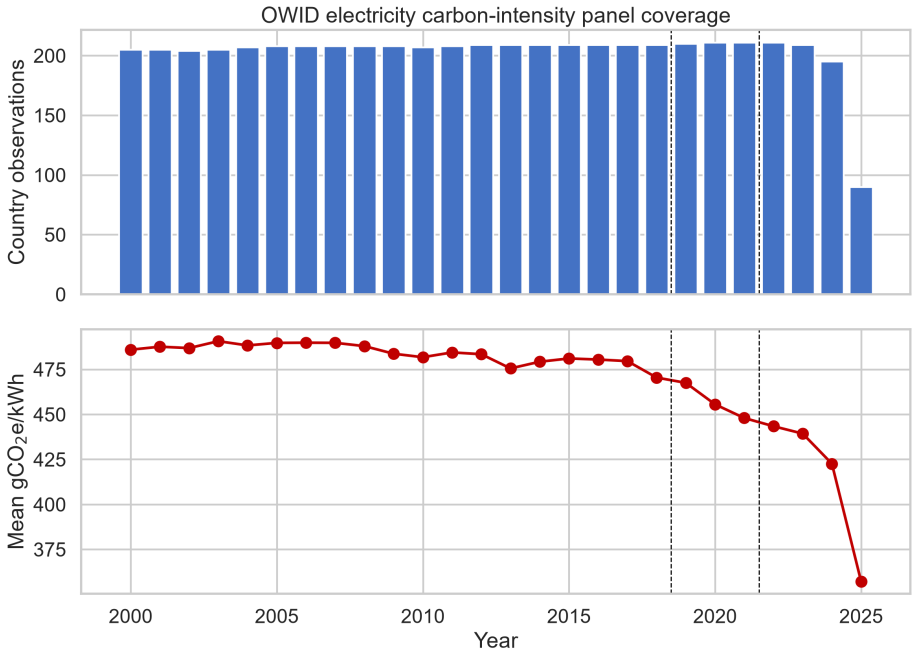


Figure 1: Độ phủ dữ liệu và cường độ carbon trung bình theo năm.

4.2 So sánh mô hình

Bảng 1 được sinh trực tiếp từ `model_metrics.csv`. Trên test 2022–2025, XGBoost có sai số thấp nhất với MAE 24.25, RMSE 41.03 gCO_2e/kWh và $R^2 = 0.972$. Kết quả validation và test có cùng thứ hạng mô hình, giảm nguy cơ kết luận chỉ dựa trên một tập duy nhất.

Table 1: Kết quả validation và temporal test.

Tập dữ liệu	Mô hình	n	MAE	RMSE	R^2
Test (2022-2025)	XGBoost	705	24.25	41.03	0.972
Test (2022-2025)	Random Forest	705	29.77	47.14	0.962
Test (2022-2025)	Linear Regression	705	43.54	77.83	0.898
Validation (2019-2021)	XGBoost	632	25.82	48.24	0.961
Validation (2019-2021)	Random Forest	632	29.97	48.78	0.960
Validation (2019-2021)	Linear Regression	632	43.60	81.83	0.887

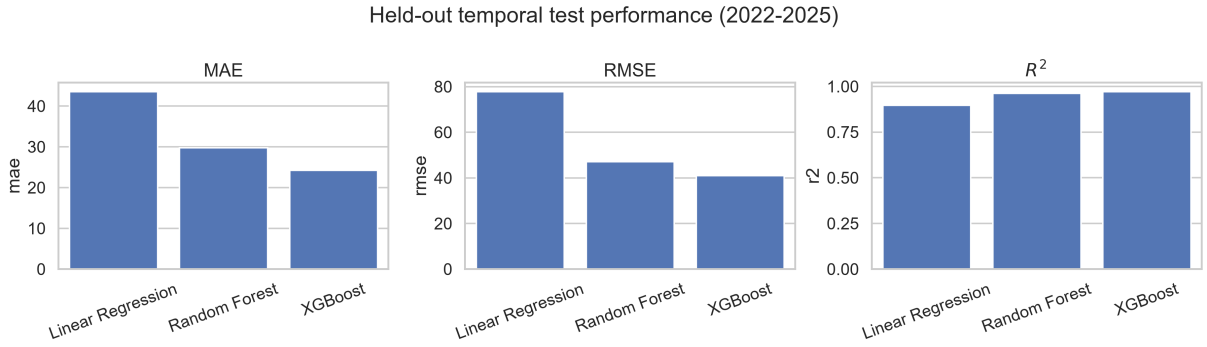


Figure 2: So sánh MAE, RMSE và R^2 trên test 2022–2025.

Hình 3 cho thấy dự đoán của mô hình tốt nhất bám gần đường $y = \hat{y}$ trên phần lớn miền giá trị. Hình 4 cho thấy phân bố phần dư theo từng năm test; độ phân tán lớn hơn ở một số năm nhấn mạnh lợi ích của báo cáo sai số theo thời gian thay vì chỉ một số tổng hợp.

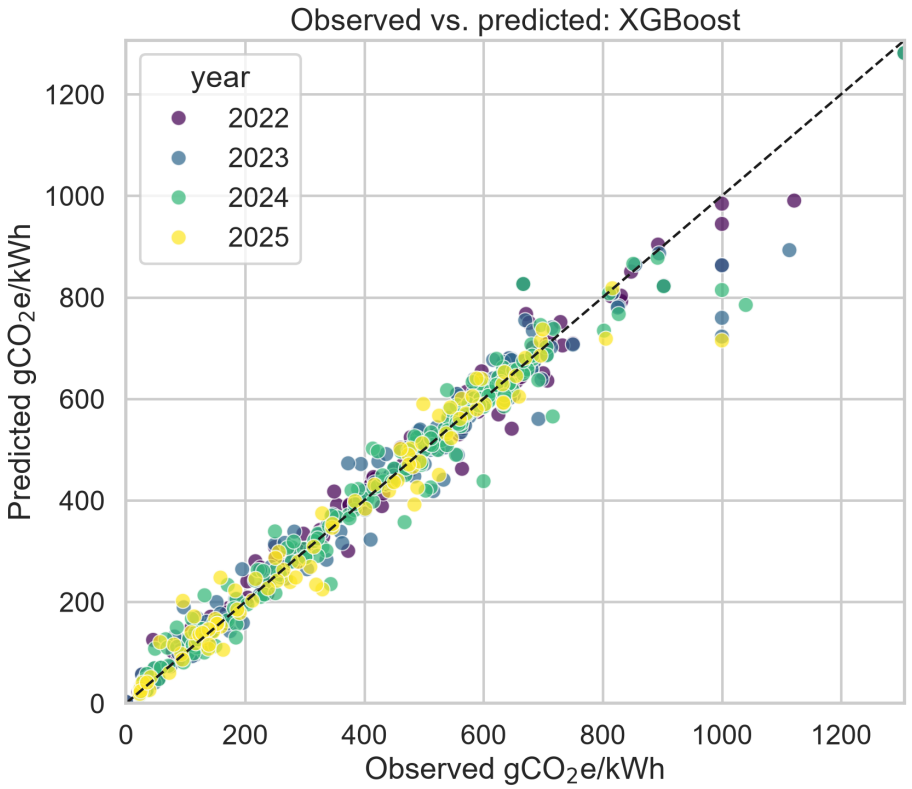


Figure 3: Giá trị quan sát và dự đoán của mô hình tốt nhất trên tập test.

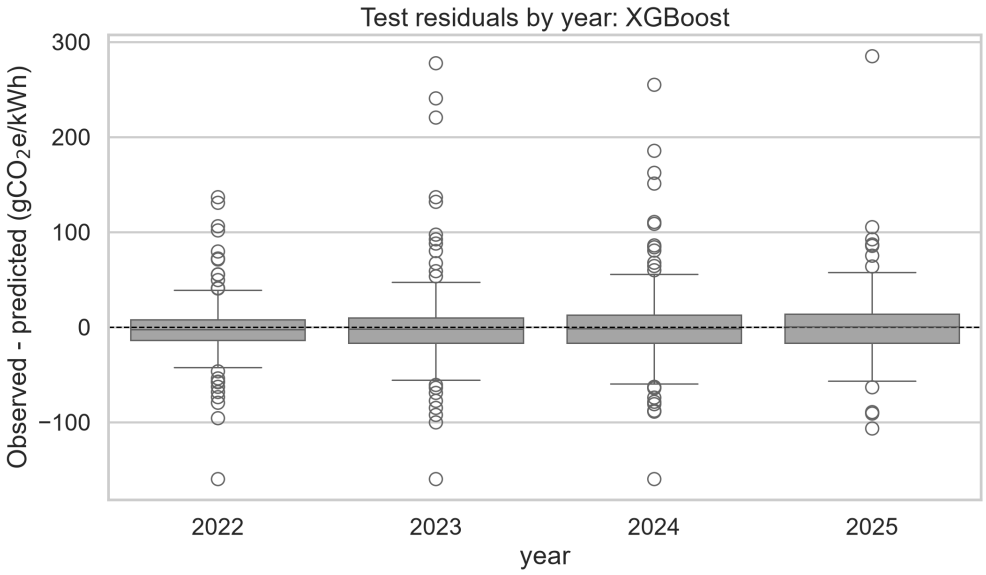


Figure 4: Phần dư test theo năm của mô hình tốt nhất.

4.3 Feature importance và SHAP

Importance nội tại của Random Forest và XGBoost được trình bày ở Hình 5. Vì importance dựa trên cách chia cây có thể ưu tiên một trong các biến tương quan, nghiên cứu bổ sung permutation importance và SHAP. Trên mẫu tối đa 500 hàng test cố định bằng seed 42, `hydro_share_elec` có mean absolute SHAP lớn nhất (Bảng 2).

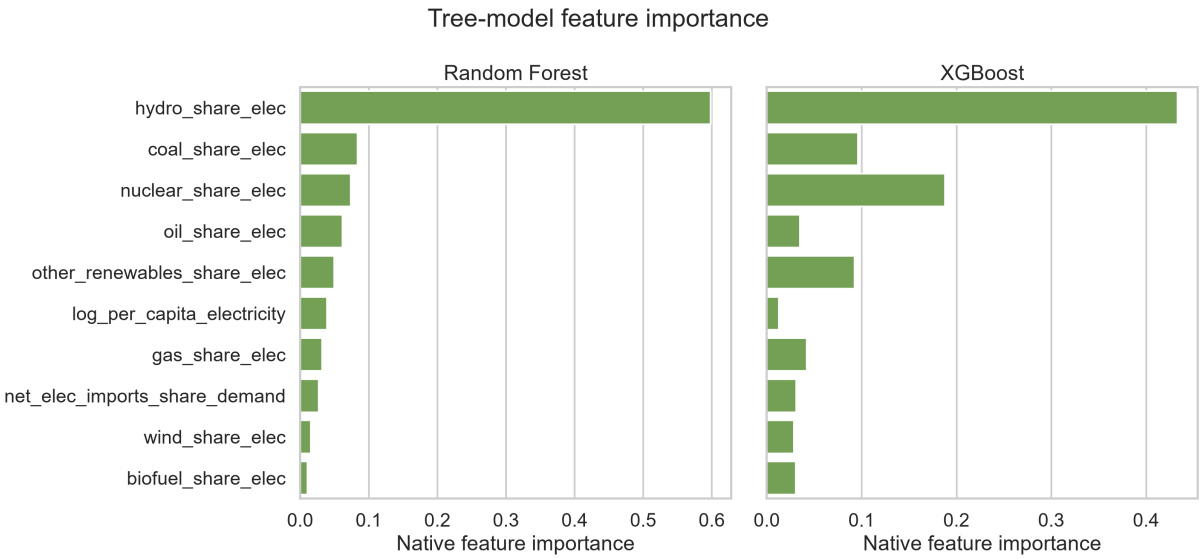


Figure 5: Feature importance nội tại của hai mô hình cây.

Table 2: Tám đặc trưng có mean absolute SHAP cao nhất của XGBoost.

Đặc trưng	Mean |SHAP|
`hydro_share_elec`	123.47
`coal_share_elec`	51.05
`oil_share_elec`	27.05
`gas_share_elec`	25.85
`nuclear_share_elec`	24.85
`solar_share_elec`	24.21
`other_renewables_share_elec`	23.10
`wind_share_elec`	22.43

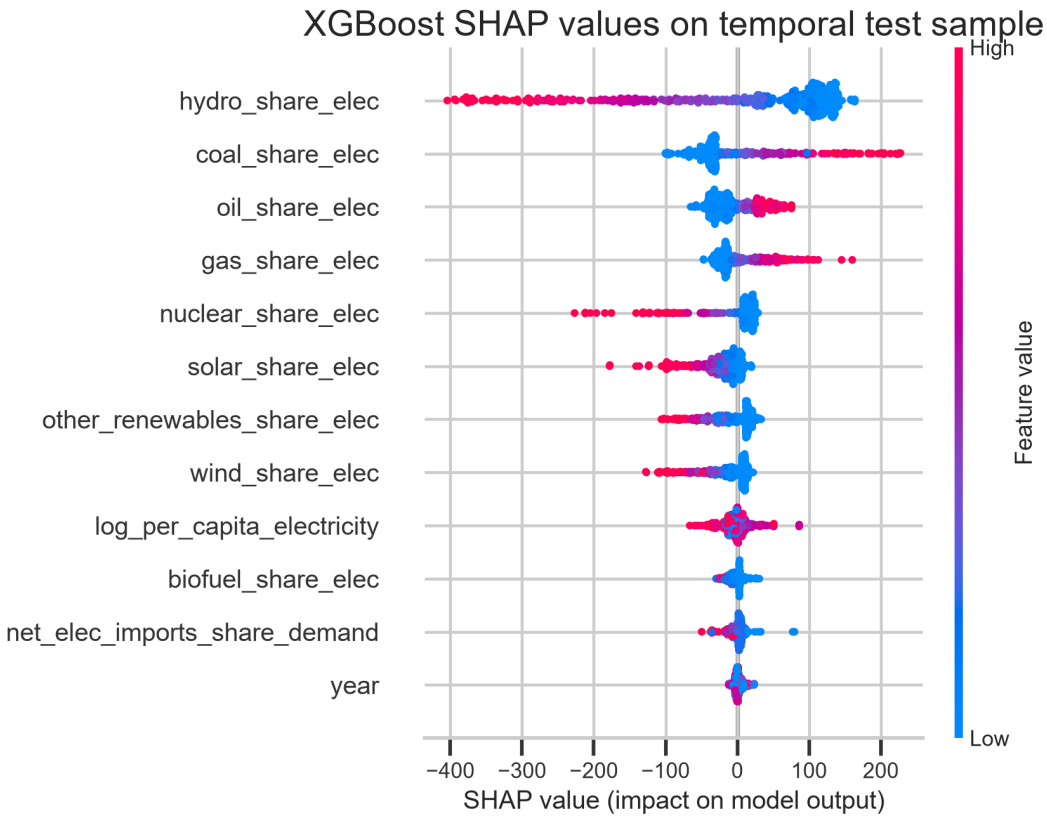


Figure 6: Phân bố SHAP của XGBoost trên mẫu test. Màu biểu diễn giá trị đặc trưng.

5 Thảo luận

XGBoost vượt Random Forest và Linear Regression trên cả validation lẫn test, cho thấy các quan hệ phi tuyến và tương tác giữa các thành phần cơ cấu điện mang thông tin dự báo đáng kể. Linear Regression vẫn đạt R^2 dương cao nhưng có RMSE lớn hơn, phù hợp với vai trò baseline. Các tỷ trọng nguồn điện chi phối SHAP là hợp lý về mặt cấu trúc vì biến đích phản ánh tổng hợp phát thải vòng đời của hỗn hợp phát điện. Tuy nhiên, một thứ hạng SHAP cao không có nghĩa tăng một điểm phần trăm của nguồn đó sẽ gây ra đúng mức thay đổi tương ứng: quan hệ cấu thành, nhập khẩu và các biến bị bỏ sót làm giới hạn diễn giải can thiệp.

Kết quả nên được dùng cho kiểm tra nhất quán dữ liệu, ước lượng giá trị thiếu hoặc nowcasting khi cơ cấu điện cùng năm đã biết. Để dự báo thực sự cho các năm chưa có cơ cấu điện, cần xây dựng biến trễ hoặc kịch bản ngoại sinh cho tỷ trọng nguồn, nhu cầu, chính sách và công suất lắp đặt; đó là bài toán khác với phạm vi hiện tại.

6 Giới hạn và nguy cơ đối với độ tin cậy

- **Độ phủ 2025:** chỉ một phần quốc gia có quan sát 2025. Metric gộp test vì vậy chịu ảnh hưởng của cấu thành mẫu và không đại diện hoàn toàn cho mọi quốc gia.
- **Phụ thuộc panel:** cùng quốc gia xuất hiện ở nhiều năm. Temporal split ngăn leakage theo năm nhưng không đo khả năng tổng quát sang quốc gia hoàn toàn chưa thấy.
- **Nowcasting thay vì dự báo dài hạn:** đặc trưng và biến đích cùng năm. Kết quả không chứng minh mô hình biết trước cơ cấu điện tương lai.

- **Dữ liệu quan sát:** sai số đo, cập nhật hồi tố và khác biệt phương pháp nguồn có thể truyền vào mô hình.
- **Diễn giải:** native importance, permutation importance và SHAP mô tả hành vi mô hình, không phải ước lượng nhân quả.
- **Tái lập theo thời gian:** OWID cập nhật thường xuyên; checksum của snapshot là điều kiện để tái tạo đúng các số liệu trong bài.

7 Khả năng tái lập

Notebook chính trong thư mục `notebooks` chạy toàn bộ quy trình từ kiểm tra nguồn tới mô hình và SHAP. Mã dùng chung nằm trong `src/carbon_intensity_workflow.py`. Seed, phiên bản thư viện, danh sách đặc trưng và split được ghi vào `environment.json`. Prediction test, metric tổng hợp, metric theo năm, lưới siêu tham số, importance, mô hình đã fit và hình đều được lưu dưới `outputs/carbon_intensity/`. Các macro và bảng trong paper được sinh từ CSV thực nghiệm, không nhập thủ công.

8 Kết luận

Nghiên cứu đã triển khai một workflow có provenance và chia dữ liệu theo thời gian để ước lượng cường độ carbon điện từ OWID/Ember giai đoạn 2000–2025. Trong ba mô hình, XGBoost đạt kết quả test tốt nhất với MAE 24.25, RMSE 41.03 gCO_2e/kWh và $R^2 = 0.972$. Kết quả hỗ trợ sử dụng mô hình cây tăng cường cho bài toán dữ liệu bảng này, đồng thời nhấn mạnh rằng hiệu năng cao không loại bỏ giới hạn về độ phủ 2025, phụ thuộc theo quốc gia và diễn giải nhân quả. Bước tiếp theo hợp lý là đánh giá leave-country-out, mô hình dùng biến trễ, và các kịch bản cơ cấu nguồn điện tương lai.

Dữ liệu và mã nguồn

Dữ liệu OWID được sử dụng theo điều kiện ghi công của nguồn. URL, thời điểm tệp, kích thước và SHA-256 được lưu trong artifact provenance. Mã, notebook và kết quả thực nghiệm đi kèm paper trong cùng repository.

References

[1] H. Ritchie, P. Rosado, and M. Roser, "Lifecycle carbon intensity of electricity generation," *Our World in Data*, data adapted from Ember, 2026. https://ourworldindata.org/grapher/carbon-intensity-electricity.

[2] Our World in Data, "Data on Energy by Our World in Data," 2026. https://github.com/owid/energy-data.

[3] Ember, "Yearly Electricity Data: Methodology," 2026. https://files.ember-energy.org/public-downloads/ember_electricity_data_methodology.pdf.

[4] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, pp. 5–32, 2001. doi: 10.1023/A:1010933404324.

[5] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, 2016. doi: 10.1145/2939672.2939785.

[6] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems 30*, 2017. https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.