Mô hình hóa có khả năng giải thích cường độ carbon của hệ thống điện quốc gia: bằng chứng từ Our World in Data, 2000–2025

[Bổ sung tên tác giả và đơn vị]

Tháng 10 năm 2026

Abstract

Cường độ carbon của điện khác biệt đáng kể giữa các quốc gia và biến động theo cơ cấu nguồn phát. Nghiên cứu này xây dựng một quy trình học máy có khả năng giải thích để mô hình hóa cường độ phát thải vòng đời của điện từ dữ liệu quốc gia–năm trong giai đoạn 2000–2025. Dữ liệu được tải từ các endpoint OWID Grapher và ghép thành panel gồm 5.267 quan sát thuộc 210 quốc gia. Sáu họ mô hình được đánh giá bằng các giao thức tách theo thời gian, quốc gia chưa thấy và chuyển giao vùng. CatBoost được lựa chọn chỉ bằng RMSE trên validation theo thời gian; trên test 2022–2025, mô hình đạt MAE 24,68, RMSE 41,04 gCO_2e/kWh và $R^2 = 0,972$. Khi đánh giá trên các quốc gia chưa xuất hiện trong train, RMSE tăng lên 110,61 và R^2 giảm còn 0,749. SHAP xếp tỷ trọng thủy điện và than là hai đặc trưng có đóng góp tuyệt đối trung bình lớn nhất. Nghiên cứu tình huống Việt Nam cho thấy dự báo năm 2025 cao hơn quan sát 70,69 gCO_2e/kWh; các kịch bản thay đổi cơ cấu nguồn chỉ được diễn giải là phản ứng ceteris paribus của mô hình, không phải tác động nhân quả hay khuyến nghị quy hoạch. Kết quả cho thấy boosting có hiệu năng nội suy theo thời gian cao, đồng thời nhấn mạnh khoảng cách tổng quát hóa giữa quốc gia và giới hạn của dữ liệu quốc gia theo năm.

Từ khóa: cường độ carbon điện; cơ cấu nguồn điện; học máy giải thích được; SHAP; CatBoost; Our World in Data.

Abstract

Abstract. This study develops an explainable machine-learning workflow for modelling the life-cycle carbon intensity of national electricity systems using country–year data from Our World in Data (OWID), 2000–2025. The assembled panel contains 5,267 observations from 210 countries. Six model families are evaluated under temporal, unseen-country, and region-transfer protocols. CatBoost is selected solely by temporal-validation RMSE and obtains a 2022–2025 test MAE of 24.68, RMSE of 41.04 gCO_2e/kWh, and $R^2 = 0.972$. On countries excluded from training, its RMSE rises to 110.61 and R^2 falls to 0.749. SHAP ranks hydro and coal shares as the two most important features by mean absolute contribution. The Vietnam case and composition scenarios are model-based, ceteris-paribus analyses, not causal estimates. The results indicate strong temporal interpolation but materially weaker transfer to unseen countries, motivating cautious use of country-level annual models.

Keywords: electricity carbon intensity; generation mix; explainable machine learning; SHAP; CatBoost; Our World in Data.

1 Giới thiệu

Điện năng là đầu vào thiết yếu cho quá trình điện hóa giao thông, công nghiệp và tòa nhà; vì vậy, phát thải gắn với mỗi đơn vị điện ảnh hưởng trực tiếp đến lợi ích khí hậu của các hoạt động sử dụng điện. Cường độ carbon vòng đời bổ sung các phát thải ngoài vận hành nhà máy vào phép đo, qua đó mở rộng cách nhìn so với chỉ tính phát thải tại điểm phát điện [3, 6]. Chỉ số này khác nhau lớn giữa các hệ thống điện, một phần do tỷ trọng than, khí, dầu, thủy điện, hạt nhân, gió và mặt trời.

Quan hệ giữa cơ cấu nguồn điện và cường độ carbon có thể phi tuyến, đồng thời các tỷ trọng là thành phần của một hỗn hợp có tổng bị ràng buộc. Mô hình tuyến tính tạo đường cơ sở dễ đối chiếu, trong khi mô hình cây có thể nắm bắt tương tác và ngưỡng nhưng cần đánh giá nghiêm ngặt ngoài mẫu và giải thích thận trọng. Đặc biệt, phép chia ngẫu nhiên từng hàng của panel có thể đặt các năm cùng quốc gia vào cả train và test, khiến hiệu năng có vẻ lạc quan khi mục tiêu là áp dụng cho năm sau hoặc quốc gia mới.

Nghiên cứu đặt ra ba câu hỏi:

1. Các mô hình học máy ước lượng cường độ carbon điện tốt đến mức nào trên các năm nằm ngoài giai đoạn huấn luyện?
2. Hiệu năng có duy trì khi chuyển sang quốc gia hoặc vùng địa lý chưa xuất hiện trong train hay không?
3. Những thành phần nào chi phối dự báo, và mô hình phản ứng ra sao trước các kịch bản thay đổi cơ cấu nguồn của Việt Nam?

Đóng góp của bài viết là: (i) xây dựng panel tái lập từ nguồn OWID Grapher có ghi nhận phiên bản và checksum; (ii) so sánh sáu họ mô hình dưới ba giao thức đánh giá bổ sung cho nhau; và (iii) kết hợp SHAP, permutation importance, partial dependence cùng phân tích tình huống Việt Nam. Toàn bộ kết quả XAI và kịch bản được diễn giải như thuộc tính của hàm dự báo, không phải bằng chứng nhân quả.

2 Dữ liệu

2.1 Nguồn và đơn vị phân tích

Đơn vị phân tích là một quốc gia trong một năm. Panel bao phủ 2000–2025, với 5.267 dòng sau quy tắc loại hàng quá thưa, thuộc 210 quốc gia và năm vùng địa lý. Các đại lượng về phát điện theo nguồn, tổng sản lượng, nhu cầu, nhập khẩu ròng, điện bình quân đầu người, dân số và GDP/người được lấy từ CSV API của OWID Grapher. Biến đích cường độ carbon được lấy từ cùng Grapher với metric `carbon_intensity`; OWID ghi nguồn Ember cho chuỗi này [3, 6, 7].

Biến đích là cường độ phát thải vòng đời, đơn vị gCO_2e/kWh. Phạm vi mô hình chính giới hạn ở thực thể quốc gia có mã ISO; Kosovo được giữ lại theo mã OWID riêng. Các tổng hợp khu vực và toàn cầu bị loại. Panel giữ các tỷ trọng nguồn điện, quy mô phát điện và nhu cầu, nhập khẩu ròng, dân số, GDP và điện bình quân đầu người để kiểm tra và mô tả dữ liệu. Dữ liệu GDP/người, phát điện tổng, điện bình quân đầu người và tổng tỷ trọng tái tạo không được dùng trong ma trận đặc trưng cuối cùng do thiếu hụt hoặc dư thừa đại số với các biến khác.

2.2 Đặc trưng và kiểm soát chất lượng

Tỷ trọng mỗi nguồn được tính bằng sản lượng của nguồn chia tổng sản lượng điện. Tỷ lệ nhập khẩu ròng được tính bằng nhập khẩu ròng chia nhu cầu. Mỗi hàng cần ít nhất 9 trong 11 trường đầu vào thô bắt buộc; 120 hàng không đáp ứng điều kiện này bị loại khỏi 5.387 hàng ban đầu. Các giá trị thiếu còn lại được điền bằng median được ước lượng bên trong pipeline trên phần train của từng fold, tránh học thông tin từ validation hoặc test.

Ma trận mô hình gồm 11 đặc trưng: tỷ trọng than, khí, mặt trời, gió, thủy điện, hạt nhân và nhiên liệu sinh học; $\log(1 + \text{nhu cầu điện})$; tỷ trọng nhập khẩu ròng trên nhu cầu; $\log(1 + \text{dân số})$; và xu thế năm tính từ 2000. Tỷ trọng dầu là thành phần tham chiếu không đưa trực tiếp vào ma trận, do tổng các tỷ trọng nguồn bị ràng buộc. Việc chọn thành phần tham chiếu được kiểm tra bằng VIF trên train; lựa chọn bỏ dầu cho VIF tối đa thấp nhất trong các lựa chọn đã xét.

3 Phương pháp

3.1 Mô hình dự báo

Với quốc gia i ở năm t, bài toán được viết:

$$y_{it} = f(\mathbf{x}_{it}) + \varepsilon_{it}, \tag{1}$$

trong đó y_{it} là cường độ carbon và $\mathbf{x}_{it}$ là vector 11 đặc trưng. Sáu họ mô hình được so sánh: Linear Regression, Ridge, Elastic Net, Random Forest, XGBoost và CatBoost. Ridge và Elastic Net cung cấp các baseline tuyến tính có điều chuẩn [4, 9]; Random Forest kết hợp nhiều cây quyết định [1]; XGBoost và CatBoost là các phương pháp boosting cây cho dữ liệu bảng [2, 8].

Các pipeline xử lý giá trị thiếu được fit trong từng tập huấn luyện; biến chuẩn hóa chỉ được áp dụng cho các mô hình tuyến tính. Siêu tham số được chọn theo RMSE validation. Với giao thức thời gian, CatBoost có cấu hình depth 6, 800 vòng lặp và learning rate 0,05; RMSE validation là 39,94 gCO_2e/kWh. Sau khi chọn cấu hình, mô hình được fit lại trên train cộng validation và chỉ sau đó đánh giá trên test.

3.2 Giao thức đánh giá

Ba giao thức kiểm tra các dạng tổng quát hóa khác nhau:

- **Theo thời gian:** train 2000–2018 (3.943 dòng), validation 2019–2021 (627 dòng), test 2022–2025 (697 dòng). Không năm nào đồng thời xuất hiện ở nhiều split.
- **Quốc gia chưa thấy:** các quốc gia được phân hoạch độc quyền theo tỷ lệ 60/20/20 với seed 42. Test gồm 42 quốc gia và 1.047 quan sát; không quốc gia nào xuất hiện trong train hoặc validation.
- **Chuyển giao vùng:** lần lượt giữ lại Africa, America, Asia, Europe hoặc Oceania; huấn luyện trên các vùng còn lại đến năm 2021 và kiểm tra trên vùng giữ lại trong 2022–2025.

Hiệu năng được báo cáo bằng MAE, RMSE và hệ số xác định:

$$\text{MAE} = \frac{1}{n}\sum_{j=1}^{n}|y_j - \hat{y}_j|, \tag{2}$$

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2}, \tag{3}$$

$$R^2 = 1 - \frac{\sum_{j=1}^{n}(y_j - \hat{y}_j)^2}{\sum_{j=1}^{n}(y_j - \bar{y})^2}. \tag{4}$$

Đơn vị MAE và RMSE là gCO_2e/kWh. Seed cố định bằng 42. Các metric test không được sử dụng để chọn mô hình hoặc siêu tham số.

3.3 Giải thích và kịch bản

SHAP phân rã dự báo thành đóng góp đặc trưng dựa trên giá trị Shapley [5]. Permutation importance đánh giá mức suy giảm dự báo khi hoán vị một đặc trưng; partial dependence mô tả đáp ứng trung bình của mô hình theo một đặc trưng. Vì các thành phần cơ cấu điện tương quan và có quan hệ thành phần, các phương pháp này mô tả mô hình đã fit chứ không nhận diện tác động độc lập hay quan hệ nhân quả.

Các kịch bản Việt Nam bắt đầu từ cấu hình quan sát năm 2025. Tỷ trọng nguồn được điều chỉnh theo tên kịch bản, trong khi nhu cầu, dân số, nhập khẩu và năm được giữ cố định. Mỗi thay đổi là một phản thực ceteris paribus trong không gian đầu vào của mô hình, không phải dự báo cân bằng hệ thống điện hay đánh giá chính sách.

4 Kết quả

4.1 Đánh giá ngoài mẫu

CatBoost được chọn dựa trên RMSE validation theo thời gian. Trên temporal test, mô hình đạt MAE 24,68, RMSE 41,04 gCO_2e/kWh và $R^2 = 0,972$. Đây là kết quả tốt nhất trong sáu mô hình theo temporal test, nhưng khoảng cách giữa validation và test cùng với sự thay đổi thành phần quốc gia theo năm gần nhất cần được tính đến khi diễn giải. Trên giao thức quốc gia chưa thấy, cùng mô hình đạt MAE 60,70, RMSE 110,61 và $R^2 = 0,749$.

Table 1: Hiệu năng của sáu mô hình trên temporal test và unseen-country test.

Giao thức	Mô hình	MAE	RMSE	R^2
Temporal test (2022–2025), $n = 697$				
	Linear Regression	49,75	82,78	0,887
	Ridge	49,75	82,78	0,887
	Elastic Net	49,73	82,78	0,887
	Random Forest	30,70	49,05	0,960
	XGBoost	27,72	47,69	0,962
	CatBoost	**24,68**	**41,04**	**0,972**
Unseen-country test, $n = 1.047$				
	Linear Regression	61,06	100,59	0,792
	Ridge	60,82	100,53	0,792
	Elastic Net	60,27	100,38	0,793
	Random Forest	65,32	115,55	0,726
	XGBoost	59,49	107,07	0,764
	CatBoost	60,70	110,61	0,749

Hiệu năng unseen-country của CatBoost kém hơn rõ rệt so với temporal test, đặc biệt theo RMSE. Trong giao thức unseen-country, Elastic Net có RMSE thấp nhất trong sáu mô hình (100,38) và R^2 cao nhất (0,793), cho thấy mô hình phi tuyến được chọn cho nội suy thời gian không đương nhiên tối ưu cho chuyển giao quốc gia. Kết quả này là lý do cần báo cáo nhiều hơn một cách chia dữ liệu.

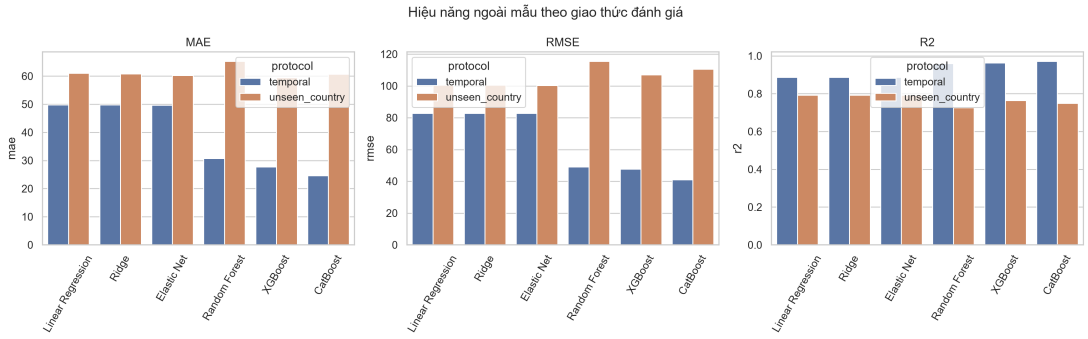


Figure 1: So sánh hiệu năng mô hình trên temporal và unseen-country test.

4.2 Chuyển giao giữa các vùng

Table 2: RMSE CatBoost khi giữ lại từng vùng địa lý.

Vùng giữ lại	Số quan sát test	RMSE (gCO_2e/kWh)
Africa	168	72,803
America	147	40,185
Asia	176	133,880
Europe	160	144,124
Oceania	46	107,399

Sai số chuyển giao dao động đáng kể theo vùng: RMSE thấp nhất ở America và cao nhất ở Europe. CatBoost không phải mô hình tốt nhất ở mọi lần giữ vùng; các mô hình tuyến tính có RMSE thấp hơn ở

Europe và Oceania. Việc giữ cả vùng ra khỏi train là phép thử ngoại suy cấu trúc nghiêm ngặt hơn phép chia thời gian trong cùng panel. Do đó, kết quả này không nên được thay thế bằng một điểm hiệu năng tổng hợp duy nhất.

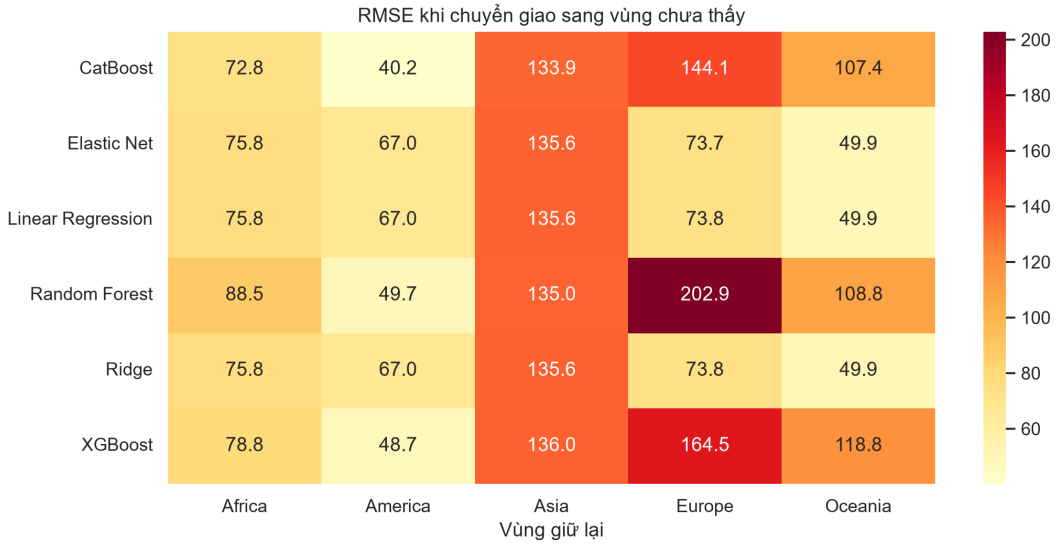


Figure 2: RMSE theo vùng được giữ lại trong giao thức chuyển giao vùng.

4.3 Giải thích mô hình

Tỷ trọng thủy điện có mean absolute SHAP lớn nhất (140,68 gCO_2e/kWh), tiếp theo là than (47,90), gió (34,63), hạt nhân (33,17) và nhiên liệu sinh học (25,63). Chênh lệch lớn của thủy điện phản ánh vai trò nổi bật của đặc trưng này trong các dự báo trên phân phối dữ liệu đã quan sát. Nó không có nghĩa một thay đổi thủy điện độc lập sẽ gây ra mức giảm/tăng tương ứng: SHAP chịu ảnh hưởng của quan hệ tương quan, thành phần và các biến không quan sát.

Table 3: Năm đặc trưng đứng đầu theo mean absolute SHAP của CatBoost.

Đặc trưng	Mean $\lvert SHAP \rvert$	Mean SHAP
Tỷ trọng thủy điện	140,68	9,73
Tỷ trọng than	47,90	-4,62
Tỷ trọng điện gió	34,63	-21,44
Tỷ trọng hạt nhân	33,17	-2,47
Tỷ trọng nhiên liệu sinh học	25,63	-8,45

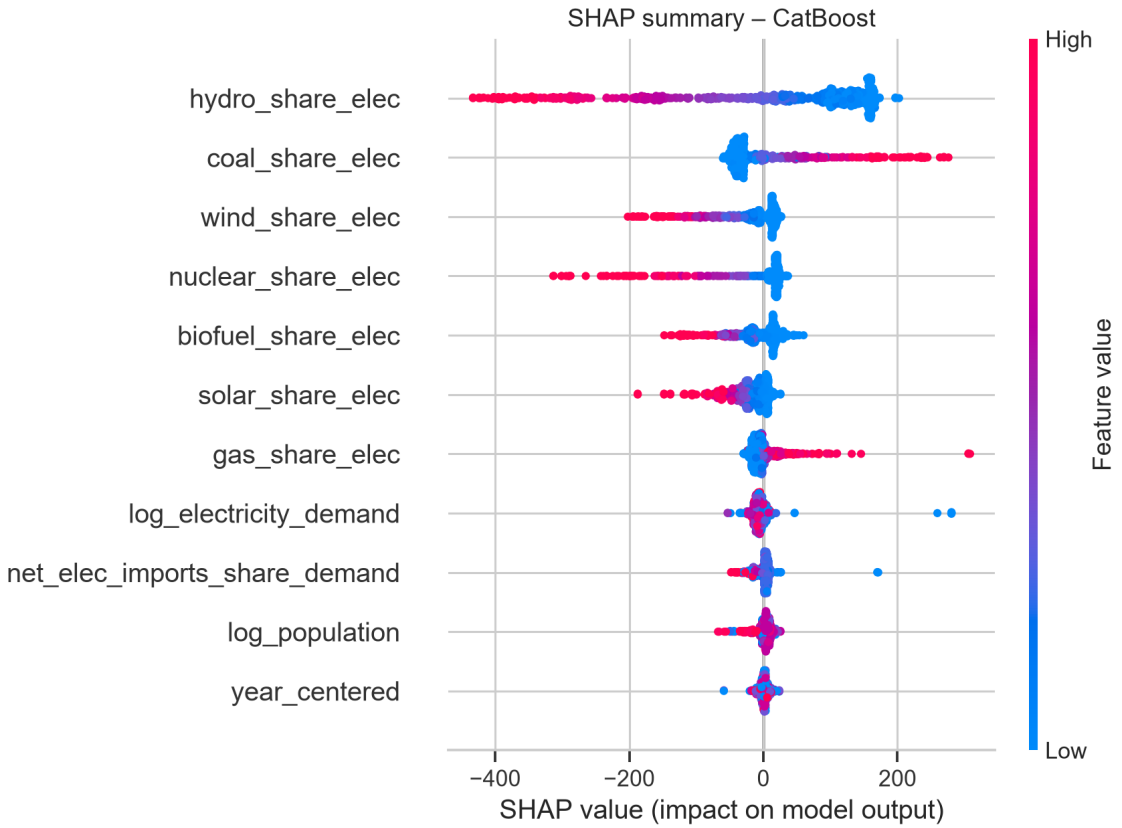


Figure 3: Phân bố đóng góp SHAP của mô hình CatBoost trên mẫu giải thích.

Permutation importance và partial dependence được dùng như các góc nhìn bổ sung cho SHAP. Sự phù hợp giữa các phương pháp có thể củng cố mô tả về hàm dự báo, nhưng không loại bỏ vấn đề phụ thuộc giữa các tỷ trọng nguồn. Hình partial dependence vì vậy cần được đọc như đáp ứng trung bình trong miền dữ liệu, không như kết quả của một can thiệp khả thi trong vận hành hệ thống.

4.4 Nghiên cứu tình huống Việt Nam

Trong dữ liệu OWID năm 2025, cường độ carbon quan sát của Việt Nam là 460,73 gCO_2e/kWh; dự báo CatBoost là 531,42, tương ứng sai số dự báo dương 70,69. Kết quả cá biệt này cho thấy hiệu năng toàn cục cao không đảm bảo độ chính xác tương đương cho từng quốc gia hoặc từng năm.

Table 4: Các kịch bản cơ cấu nguồn điện giả định cho Việt Nam năm 2025.

Kịch bản	Dự báo (gCO_2e/kWh)	Thay đổi (gCO_2e/kWh)	Thay đổi (%)
Quan sát cơ sở	531,42	0,00	0,00
Mặt trời +5 điểm, than -5 điểm	482,85	-48,57	-9,14
Gió +5 điểm, than -5 điểm	470,29	-61,13	-11,50
Mặt trời +5, gió +5, than -10 điểm	427,48	-103,94	-19,56
Hạt nhân +5 điểm, than -5 điểm	470,57	-60,86	-11,45
Thủy điện -5 điểm, khí +5 điểm	573,88	42,46	7,99

Trong các cấu hình được kiểm tra, kịch bản tăng 5 điểm phần trăm mặt trời và 5 điểm gió, đồng thời giảm 10 điểm than, tạo mức giảm dự báo lớn nhất (103,94 gCO_2e/kWh). Kịch bản thay 5 điểm thủy

điện bằng khí làm dự báo tăng 42,46. Đây là chênh lệch đầu ra khi giữ các biến khác cố định; phép thử không mô hình hóa tính khả thi về lưới điện, công suất dự phòng, lưu trữ, chi phí, an ninh cung cấp hay đáp ứng nhu cầu.

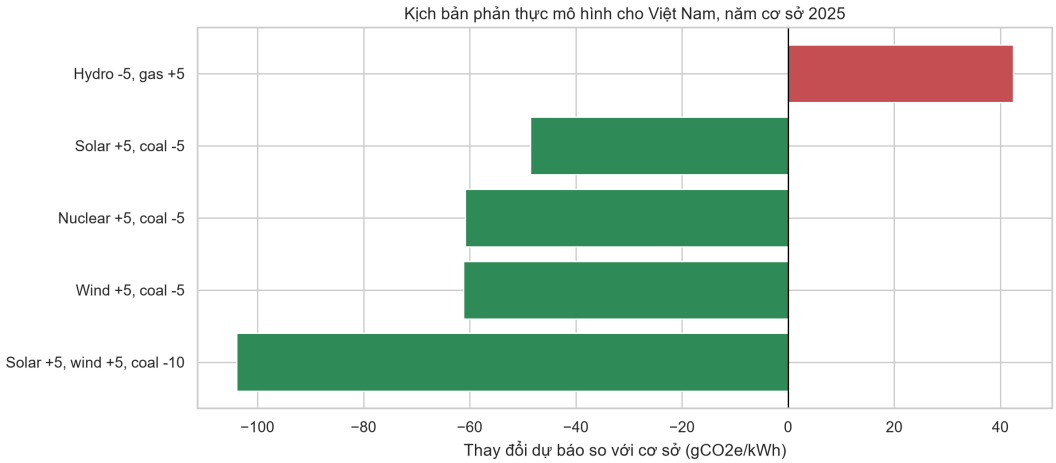


Figure 4: Dự báo CatBoost trong các kịch bản thay đổi tỷ trọng nguồn điện của Việt Nam.

5 Thảo luận

Kết quả cho thấy mô hình boosting cây biểu diễn tốt dữ liệu theo thời gian khi các quốc gia đã xuất hiện trong tập huấn luyện. Lợi thế của CatBoost trước các mô hình tuyến tính và các boosting khác trên temporal test phù hợp với giả thuyết về quan hệ phi tuyến và tương tác giữa cơ cấu nguồn và cường độ carbon. Tuy nhiên, giảm hiệu năng trên unseen-country test và độ biến thiên lớn trong region-transfer cho thấy chất lượng nội suy không thể được xem là bằng chứng cho khả năng chuyển giao phổ quát.

Một nguyên nhân quan trọng là đặc trưng và biến đích đều được đo trong cùng năm. Vì vậy, bài toán chính là mô hình hóa hoặc nowcasting có điều kiện trên cơ cấu điện hiện thời, không phải dự báo nhiều năm trước khi biết cơ cấu đó. Nếu mục tiêu là dự báo tương lai, cần dự báo hoặc quy định ngoại sinh các biến đầu vào như cơ cấu nguồn, nhu cầu và nhập khẩu, rồi đánh giá toàn bộ chuỗi dự báo theo thiết kế riêng.

Các kết quả SHAP và kịch bản có thể hỗ trợ kiểm tra tính hợp lý của dự báo, phát hiện trường hợp cần xem xét và khảo sát độ nhạy cục bộ. Chúng không thay thế phân tích nhân quả hoặc mô hình tối ưu hóa hệ thống điện. Đặc biệt, tính thành phần của tỷ trọng nguồn khiến việc thay đổi một thành phần trong khi không cân đối thành phần còn lại có thể tạo điểm nằm ngoài miền dữ liệu thực.

5.1 Hạn chế

1. Dữ liệu theo năm ở cấp quốc gia che lấp khác biệt theo giờ, vùng lưới, công nghệ và cấu trúc vận hành.

2. Các số liệu OWID có thể được cập nhật hồi tố; độ phủ năm 2025 chưa đồng nhất giữa các quốc gia. Vì thế, khả năng tái lập chính xác đòi hỏi lưu lại snapshot nguồn và checksum đi kèm lần chạy.

3. Bổ sung median giúp pipeline xử lý dữ liệu thiếu nhưng không khắc phục thiên lệch nếu thiếu dữ liệu có hệ thống.

4. SHAP, permutation importance và partial dependence chịu ảnh hưởng bởi tương quan và phân phối quan sát; chúng không nhận dạng hiệu ứng nhân quả.

5. Kịch bản Việt Nam giữ các biến khác không đổi và không áp đặt ràng buộc kỹ thuật, kinh tế hoặc chính sách của hệ thống điện.

6 Kết luận

Bài viết xây dựng và đánh giá một quy trình học máy có khả năng giải thích cho cường độ carbon vòng đời của điện quốc gia trong giai đoạn 2000–2025. Trên panel 5.267 quan sát thuộc 210 quốc gia, CatBoost đạt RMSE 41,04 gCO_2e/kWh trên temporal test, nhưng RMSE tăng lên 110,61 khi đánh giá trên các quốc gia chưa thấy. SHAP xác định tỷ trọng thủy điện và than là hai đặc trưng có đóng góp tuyệt đối trung bình lớn nhất trong mô hình được chọn. Kịch bản Việt Nam cho thấy dự báo nhạy với các thay đổi tỷ trọng nguồn, song không thể diễn giải thành tác động chính sách.

Kết luận thực tiễn là mô hình có ích cho mô hình hóa có điều kiện, so sánh và thăm dò độ nhạy trong phạm vi dữ liệu đã quan sát. Trước khi dùng để lập kế hoạch hoặc chuyển giao sang quốc gia mới, cần kiểm định ngoài mẫu phù hợp, định lượng bất định và tích hợp mô hình hệ thống điện với các ràng buộc vận hành. Hướng tiếp theo gồm backtesting qua nhiều cửa sổ thời gian, dữ liệu có tần suất cao hơn, mô hình phân cấp theo quốc gia/vùng và thiết kế nhận dạng nhân quả cho câu hỏi chính sách.

Khả năng tái lập và nguồn dữ liệu

Notebook thực nghiệm và mã nguồn nằm trong repository dự án. Các bảng kết quả, dự báo, hình, mô hình đã fit, audit dữ liệu và manifest chạy được lưu dưới `outputs/thesis/`. Lần chạy ghi lại seed, phiên bản thư viện, URL nguồn và SHA-256 của các tệp tải về. Do OWID Grapher có thể được cập nhật, các con số trong bài gắn với snapshot đã lưu trong artifact, không nhất thiết trùng một lần tải dữ liệu mới trong tương lai.

References

[1] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001. doi: 10.1023/A:1010933404324.

[2] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016. doi: 10.1145/2939672.2939785.

[3] Ember. Yearly electricity data: Methodology. https://files.ember-energy.org/public-downloads/ember_electricity_data_methodology.pdf, 2026. Accessed October 2026.

[4] Arthur E. Hoerl and Robert W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970. doi: 10.1080/00401706.1970.10488634.

[5] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[6] Our World in Data. Lifecycle carbon intensity of electricity generation. https://ourworldindata.org/grapher/carbon-intensity-electricity, 2026. Data adapted from Ember; accessed October 2026.

[7] Our World in Data. Electricity mix: Generation, demand and carbon intensity. https://ourworldindata.org/grapher/electricity-mix, 2026. OWID Grapher data; accessed October 2026.

[8] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[9] Hui Zou and Trevor Hastie. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2):301–320, 2005. doi: 10.1111/j.1467-9868.2005.00503.x.